


experiment_hc_3 분석 리포트

0. 요약

hc_3는 hc_2에서 실패했던 "sink hard gate cascade"를 버리고, attention sink를 **차단용 1차 필터**가 아니라 **내부 이상 패턴 feature**로 재구성한 실험이다. 실험 순서는 다음과 같다.

1. Active SinkProbe
2. Prompt-Level Aggregation
3. Two-Branch Cascade
4. Counterfactual validation proxy

핵심 결론은 명확하다. **Active SinkProbe + Prompt-Level Aggregation** 조합은 현재 hc_3 결과에서 가장 강한 방어 후보다. pos0/pos1 모두 prompt-level logreg aggregation이 held-out prompt split에서 attack block-rate 1.0, prompt FPR 0.0, ASR after 0.0을 기록했다. 반면 Two-Branch Cascade는 공격 차단력은 높지만 prompt FPR이 0.11801로 높아, 현재 상태에서는 최종 방어라기보다 branch 진단/보조 feature로 보는 것이 맞다.



1. 입력 데이터와 평가 설정

분석 대상은 [experiments_hc_3/results/hc3_active_sink](#)에 있는 최신 결과다. 이 결과는 hc_2와 호환되는 extraction artifact를 hc_3로 복사한 뒤, model-free 분석 stage 08-11을 수행한 것이다.

데이터 규모:

항목	값
raw token rows	20,912
balanced token rows	2,184
hidden layers	33
attention layers	32
hidden dim	4,096
cap mode	balanced

항목	값
cap per category/position	156

balanced view에서는 A-G 모든 category가 312개씩 맞춰져 있다. pos0/pos1 각각에서는 전체 1,092 rows가 있고, A reference를 제외한 binary fitting 대상은 936 rows다. positive는 B/D 312개, negative는 C/E/F/G 624개다.

ASR 기준은 **both**이며, Llama-Guard 결과도 포함되어 있다.

variant	n	keyword ASR	Llama-Guard ASR
B malicious mimicry	150	30.00%	8.67%
D malicious special	150	56.67%	42.67%
F positioned regular	150	14.00%	6.00%


F가 완전한 0 ASR이 아니라는 점은 중요하다. F는 position-only negative control이지만, refusal-keyword/guard 기준에서는 일부 성공처럼 보이는 prompt가 존재한다. 따라서 방어 평가는 token-level FPR뿐 아니라 prompt-level ASR after를 같이 봐야 한다.

2. Stage 08: Active SinkProbe

Active SinkProbe는 기존의 raw sink score만 쓰지 않고 다음 feature를 함께 사용한다.

feature group	의미
sink	token이 이후 token들로부터 받는 평균 attention mass
sink_rank_pct	같은 prompt/pos_offset 안에서의 sink rank percentile
sink_top{k}	top-k sink 후보 포함 여부
value_norm, output_norm	attention value/output의 계산 영향 크기
active_value	$\text{sink} * \text{value_norm}$
active_output	$\text{sink} * \text{output_norm}$
hidden_norm	hidden state norm trajectory
trajectory summaries	early/middle/late/max/last-first 요약

현재 artifact는 full per-head/all-token attention map이 아니라 labeled-token mean-over-head sink만 저장하고 있다. 따라서 hc_3의 SinkProbe는 "labeled-token SinkProbe"이며, 추후 per-head/all-token extractor로 확장할 수 있다.



2.1 분류 성능

position	Group CV AUC	balanced acc	n	positive	negative
pos0	0.99887	0.98878	936	312	624
pos1	0.99904	0.98798	936	312	624


결과적으로 B/D와 C/E/F/G는 Active SinkProbe feature 공간에서 거의 완전히 분리된다. 이 결과는 hc_2의 "full hidden representation은 강하지만 scalar cascade는 실패"라는 결론을 업데이트한다. sink를 단일 threshold/gate로 쓰면 약하지만, sink rank, active sink, norm trajectory를 묶으면 매우 강해진다.

2.2 Category별 score 분포

position	B mean	D mean	C mean	E mean	F mean	G mean
pos0	0.95334	0.89818	0.06122	0.03865	0.03729	0.05405
pos1	0.96068	0.92978	0.06869	0.00520	0.01603	0.06997

B와 D는 모두 높은 score에 몰려 있고, C/E/F/G는 대부분 낮다. 특히 C는 "같은 mimicry token이 benign context에 있는 경우"라 가장 중요한 confound인데, 평균 score가 pos0 0.06122, pos1 0.06869로 낮게 유지된다. 이는 detector가 token identity만 외운 것이 아니라 context-sensitive 내부 패턴을 잡고 있다는 근거다.

2.3 단일 feature 관찰



pos0에서는 active sink 계열이 raw sink보다 약간 더 강하다.


pos0 top single feature	AUC	direction
active_value_L3	0.92044	lower is attack
active_output_L3	0.91716	lower is attack
sink_L3	0.91242	lower is attack
active_value_early_mean	0.90284	lower is attack
hidden_norm_L18	0.90137	lower is attack

중요한 점은 direction이 “lower is attack”이라는 것이다. 즉 MetaBreak의 공격 token은 항상 “높은 sink”로 나타나는 것이 아니다. 초반 layer에서 sink/active-sink가 낮아지는 패턴도 공격 신호가 될 수 있다. 이 점 때문에 hc_2의 “sink가 높은 token만 keep” 방식은 구조적으로 recall을 잃기 쉽다.

pos1에서는 hidden norm 중후반 layer가 가장 강하다.


pos1 top single feature	AUC	direction
hidden_norm_L20	0.93929	lower is attack
hidden_norm_L22	0.93871	lower is attack
hidden_norm_L24	0.93367	lower is attack
hidden_norm_L23	0.93312	lower is attack
hidden_norm_L25	0.93109	lower is attack

따라서 pos0은 active sink가 특히 중요하고, pos1은 attack effect가 hidden trajectory로 더 선명하게 전파되는 것으로 해석할 수 있다.



3. Stage 09: Prompt-Level Aggregation

Prompt-Level Aggregation은 hc_3에서 가장 좋은 결과를 낸 방어 후보이다. token-level detector를 너무 보수적으로 쓰지 않고, prompt 단위로 max/mean/top3/count 등의 feature를 모아 최종 block 여부를 판단한다.



3.1 결과

position	strategy	attack block	prompt FPR	ASR before	ASR after	block@successful
pos0	any-token	0.92553	0.00000	0.52128	0.04255	0.91837
pos0	prompt-logreg	1.00000	0.00000	0.52128	0.00000	1.00000
pos1	any-token	0.91489	0.00000	0.52128	0.07447	0.85714
pos1	prompt-logreg	1.00000	0.00000	0.52128	0.00000	1.00000

pos0/pos1 모두 prompt-logreg가 held-out split에서 성공한 공격을 전부 차단했고, benign prompt FPR은 0.0으로 측정되었다.

이 결과가 hc_2 cascade와 다른 이유는 두 가지다.

1. hc_2는 sink를 1차 hard gate로 사용해서 낮은 sink token을 버렸다. hc_3는 sink를 feature로 사용하고, 낮은 sink 이상도 공격 신호로 허용한다.
2. hc_2는 token-level threshold 중심이었다. hc_3는 prompt-level aggregation으로 최종 결정을 내린다.


즉 hc_3의 핵심 성과는 "attention sink score 자체"보다 "sink-derived feature를 prompt-level decision으로 올리는 방식"이다.

4. Stage 10: Two-Branch Cascade

Two-Branch Cascade는 B branch와 D branch를 분리한다.

branch	positive	negative
B branch	B malicious mimicry	C/E/F/G
D branch	D malicious special	C/E/F/G

그 후 deployment proxy로 $\max(B_score, D_score)$ 를 사용했다.



4.1 결과

position	B branch AUC	D branch AUC	combined AUC	attack block	prompt FPR	ASR after
pos0	1.00000	1.00000	1.00000	1.00000	0.11801	0.00000
pos1	1.00000	0.99880	0.99910	0.99048	0.11801	0.00000

Per-type flagged rate:

position	B	D	C	E	F	G
pos0	1.00000	1.00000	0.04762	0.02222	0.00000	0.03922
pos1	1.00000	0.96429	0.04762	0.00000	0.00000	0.05882


Two-Branch는 token-level benign FPR이 0.02591로 낮아 보이지만, prompt-level FPR은 0.11801이다. 즉 token-level에서는 적은 수의 benign token만 flag되지만, prompt 단위로 보면 benign prompt 중 약 11.8%가 최소 하나의 suspicious token을 갖는다.

따라서 현재 Two-Branch Cascade는 최종 방어로 바로 쓰기에는 calibration이 부족하다. 하지만 branch별 분리 가능성이 매우 높기 때문에 다음 두 용도로는 유용하다.

1. B mimicry regular attack과 D literal special misuse의 내부 패턴 차이 분석
2. Prompt aggregation에 들어갈 branch score feature 제공

5. Stage 11: Counterfactual Validation Proxy

현재 stage 11은 true counterfactual forward가 아니라 artifact paired proxy다. 즉 prompt 자체를 바꿔 다시 forward한 것이 아니라, 기존 paired control prompt들의 score 차이를 비교한다.



5.1 결과

position	pair	n	mean delta	median delta	frac positive	paired AUC
pos0	B-F	128	0.91611	0.96882	1.00000	1.00000
pos0	D-F	128	0.85974	0.90941	0.99219	0.99951
pos1	B-F	128	0.94669	0.96079	1.00000	1.00000
pos1	D-F	128	0.93046	0.96309	1.00000	1.00000

공격 prompt score가 positioned regular control보다 거의 항상 높다. 이는 Active SinkProbe score가 단순 position artifact가 아니라 공격 구조를 반영한다는 강한 근거다.

하지만 현재 delta table에는 B-C, D-E pair가 없다. 이유는 C/E control prompt의 `prompt_idx`가 공격 prompt와 1:1로 직접 매칭되지 않는 구조이기 때문이다. 대신 `counterfactual_manifest.jsonl`에는 true rerun용 pair가 300개 생성되어 있다. 다음 단계에서는 이 manifest를 사용해서 실제 counterfactual forward를 수행해야 한다.

6. 종합 평가

6.1 가장 성공적인 방법

현재 최고 조합은 다음과 같다.

Active SinkProbe -> Prompt-Level Aggregation

이 조합은 다음 조건을 동시에 만족했다.

조건	결과
B/D 분리	Group CV AUC 약 0.999
C confound 억제	C mean score pos0 0.06122, pos1 0.06869
prompt-level block	pos0/pos1 모두 1.0
prompt FPR	pos0/pos1 모두 0.0
ASR after	pos0/pos1 모두 0.0

따라서 hc_3 결과만 보면, "sink score는 gate가 아니라 representation feature로 써야 한다"는 가설이 강하게 지지된다.

6.2 hc_2 cascade 실패와의 차이

hc_2에서 cascade가 실패한 이유는 sink를 "높으면 의심"이라는 단일 방향 gate로 사용했기 때문이다. hc_3 결과는 공격 신호가 다음처럼 더 복잡하다는 점을 보여준다.

관찰	의미
pos0 active_value_L3 가 raw sink_L3 보다 높음	sink와 value 계산 영향 결합이 유효
pos0 top features가 lower-is-attack	공격 token이 항상 high sink는 아님
pos1은 hidden_norm 중후반 layer가 강함	공격 효과가 후속 위치에서 hidden trajectory로 전파
prompt aggregation이 token threshold보다 강함	방어 단위는 token보다 prompt가 적함

즉 attention sink score는 "토큰을 줄이는 필터"가 아니라 "내부 계산 경로의 이상 징후"로 써야 한다.

6.3 아직 주의해야 할 점

1. 현재 SinkProbe는 full per-head SinkProbe가 아니다. hc_2 artifact의 한계 때문에 labeled-token mean-over-head sink를 사용한다.
2. prompt aggregation 결과가 매우 좋지만, 아직 완전한 nested validation은 아니다. hyperparameter와 stage 설계가 같은 실험군에서 정해졌기 때문에 독립 test set이 필요하다.
3. Two-Branch Cascade는 prompt FPR 0.11801로 높다. branch score는 최종 차단기보다 보조 feature로 쓰는 것이 적절하다.
4. Counterfactual validation은 아직 proxy다. true counterfactual forward가 필요하다.
5. 현재 결과는 Llama-3.1-8B-Instruct 중심이다. 모델 간 일반화는 아직 검증되지 않았다.

7. 다음 진행 방향

7.1 바로 해야 할 실험

1. True counterfactual forward 실행

`counterfactual_manifest.jsonl`의 `attack_text`와 `counterfactual_text`를 실제로 다시 forward해서 Active SinkProbe score가 얼마나 변하는지 측정해야 한다. 이 실험이 성공하면 “detector가 단순 correlation이 아니라 attack structure의 causal effect를 본다”는 주장을 만들 수 있다.

2. Independent prompt split 재실험

현재 prompt aggregation은 매우 좋은 결과를 냈지만, 독립 split에서 다시 확인해야 한다. 추천 방식은 prompt index 기준 train/validation/test를 고정하고, threshold와 aggregation model을 validation에서만 선택한 뒤 test를 마지막에 한 번만 보는 것이다.

3. Sink-only / active-sink-only / hidden-only ablation

지금 Active SinkProbe에는 sink, active sink, norm, hidden_norm이 모두 들어간다. 방어 논리를 날카롭게 만들려면 다음 ablation이 필요하다.

ablation	목적
sink-only	attention sink 개념만으로 가능한 성능
active-sink-only	sink × value/output의 기여
hidden-only	기존 hidden representation 대비 개선 여부
no-hidden Active SinkProbe	실제 경량 monitor 가능성

4. Two-Branch score를 prompt aggregation에 통합

Two-Branch 단독 cascade는 prompt FPR이 높지만 branch AUC는 매우 좋다. 따라서 최종 block에는 쓰지 말고, prompt aggregation feature로 `B_branch_max`, `D_branch_max`, `B-D margin`을 추가하는 것이 좋다.

7.2 extractor 개선

다음 extractor에서는 아래 artifact를 추가 저장하는 것이 좋다.

추가 artifact	이유
per-head sink tensor	진짜 SinkProbe-style head/layer selection
all-token sink rank	labeled-token rank bias 제거
user/template span mask	template sink displacement 측정
value/output per head	computationally active sink를 더 정확히 계산
counterfactual pair id	B-C, D-E pair delta 자동 계산

현재 figure/분석에서 보듯, labeled-token만으로도 성능은 매우 높지만 논문식 주장에는 per-head/all-token 기반이 더 설득력 있다.

7.3 최종 방어 후보

현재 기준 최종 방어 설계는 다음이 가장 좋다.

Stage 0: known input-side/L2 guard
 Stage 1: Active SinkProbe token scoring
 Stage 2: Prompt-Level Aggregation
 Stage 3: gray-zone prompt만 full hidden probe 또는 counterfactual rerun

여기서 sink는 더 이상 hard gate가 아니다. sink는 active_sink/rank/trajectory feature로 사용되고, 최종 block은 prompt-level에서 결정한다. 이 방향이 hc_2의 실패를 가장 직접적으로 해결한다.

8. 생성된 산출물

Figure:

file	내용
fig01_data_asr.png	데이터 규모와 ASR baseline
fig02_active_sinkprobe_scores.png	B-G score 분포
fig03_feature_auc_heatmap.png	feature family/layer별 AUC
fig04_prompt_aggregation.png	prompt aggregation 성능
fig05_two_branch_per_type.png	two-branch per-type flagged rate
fig06_counterfactual_deltas.png	paired-control delta 분포
fig07_sparse_coefficients.png	sparse probe coefficient 구조

Report/figure 생성 스크립트:

```
python experiments_hc_3\results_report\make_figures.py
```